LAPORAN PRAKTIKUM

MACHINE LEARNING

Dosen Pengampu: Asep Erlan Maulana, S. Kom, M. Kom

Disusun oleh:

Nama	:	Siti Murhayaroh
NIM	:	241011402534
Kelas	:	05 TPLP 018

TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PAMULANG

TAHUN 2025/2026

PERTEMUAN 4
DATA COLLECTING

A. LANDASAN TEORI

1. Pengenalan machine learning

   Didefinisikan oleh Arthur Samuel (1959) sebagai bidang studi yang memberikan komputer kemampuan untuk belajar tanpa diprogram secara eksplisit. Paradigma ML membalik alur tradisional: sistem menerima Data dan Solusi/Label sebagai masukan untuk mempelajari pola dan menghasilkan Aturan. Berbeda dengan pemrograman Tradisional yang memasukkan Aturan (Rules) dan Data ke dalam sistem untuk menghasilkan Solusi/Keluaran. Sifatnya kaku (rigid) karena bergantung pada logika if-else dan feature extraction manual yang rumit.

2. Kategori Machine Learning

   Machine learning memiliki 4 kategori, yaitu:

   1) Supervised Learning, yaitu pelatihan menggunakan data yang sudah memiliki label (target). Contoh kasus: Klasifikasi dan Regresi.
   2) Unsupervised Learning, yaitu pelatihan menggunakan data tanpa label untuk mencari pola tersembunyi/struktur mandiri. Contoh kasus: Clustering dan Dimensionality Reduction.
   3) Semi-Supervised Learning, yaitu kombinasi data berlabel (sebagian kecil) dan tidak berlabel (sebagian besar). Contoh: Pengenalan wajah di Google Photos.
   4) Reinforcement Learning, yaitu pembelajaran berbasis trial-and-error menggunakan sistem Reward dan Penalty berdasarkan interaksi Agent dengan Environment.

3. Tools, Library, Dan Alur Kerja (Workflow)

   Berikut ini environment & Library Utama Python yang akan digunakan pada praktikum kali ini:

   1) Interactive Tools (Notebook) menggunakan Jupyter Notebook
   2) Library Analisis & Komputasi menggunakan library NumPy untuk manipulasi array/matriks dan Pandas untuk analisis dan pembersihan data tabel.

3) Library Visualisasi menggunakan Matplotlib untuk pembuatan grafik 2D.
4) Library ML & Deep Learning menggunakan Scikit-Learn yang merupkan algoritma ML klasik.

4. Tahapan Workflow Machine Learning

Berikut ini tahapan dalam machine learning:

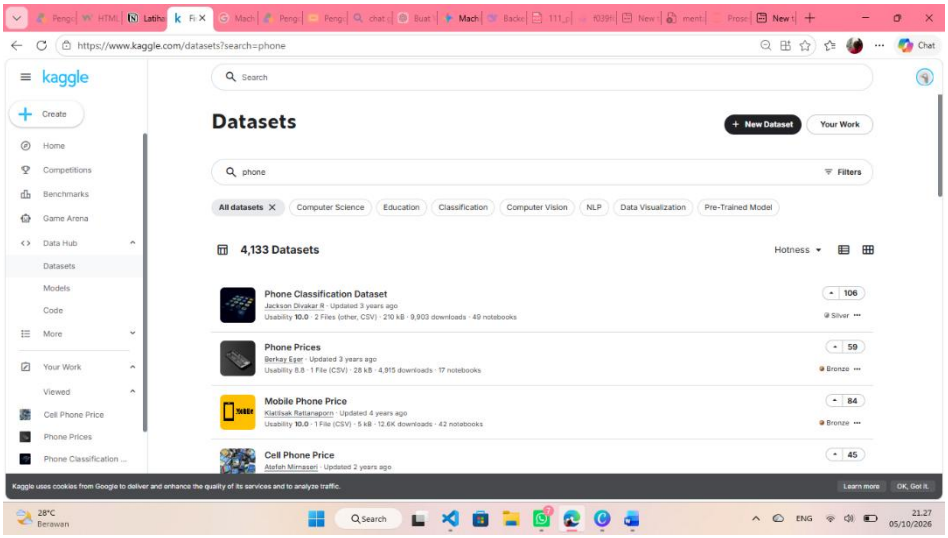
1) Data Collecting: Pengumpulan dataset dari berbagai sumber internal maupun publik.
2) Exploratory Data Analysis (EDA): Proses eksplorasi statistik dan visualisasi untuk menemukan pola awal dan anomali data.
3) Data Preprocessing: Pembersihan data (penanganan missing values, outliers, normalisasi/standarisasi, dan encoding variabel kategorikal).
4) Model Training: Pembagian data (Train-Test Split) dan pelatihan algoritma ML.
5) Model Evaluation: Pengujian performa model menggunakan metrik evaluasi (seperti Accuracy, Precision, Recall, MAE, R-Squared, Silhouette Score).
6) Deployment: Mengintegrasikan model ke sistem produksi (API, web, atau mobile).
7) Monitoring: Pemantauan kinerja model secara berkala terhadap data drift dan kebutuhan retraining.

B. TUGAS PRAKTIKUM

1. PRAKTIKUM: PENGUMPULAN DATA (DATA COLLECTING)

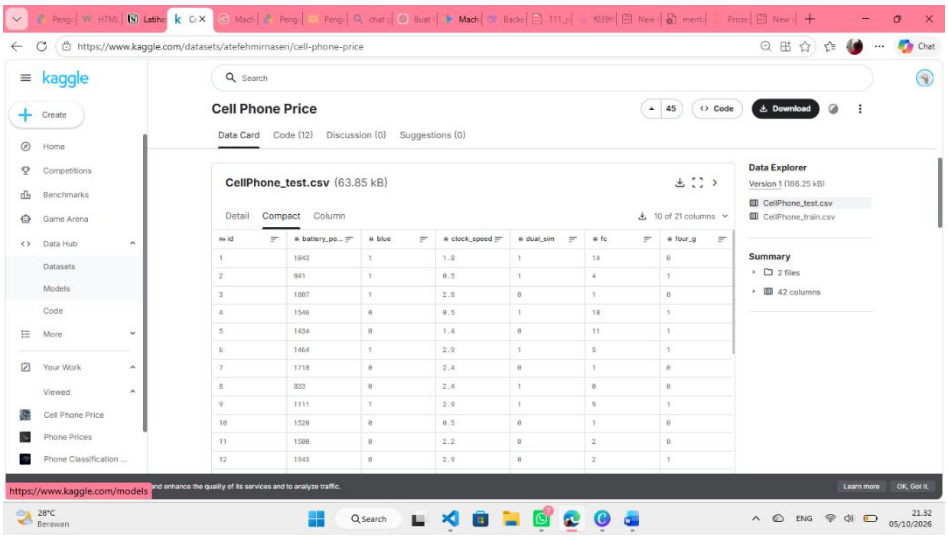
Pada praktikum kali ini penulis memilih kasus dengan target kolom berupa prediksi rentang harga *(price range)* handphone berdasarkan fitur atau spesifikasi (baterai, Ram, dll) yang ada di hp tersebut. Data tersebut diambil dari laman web https://www.kaggle.com

2. Prosedur Eksekusi Praktikum (Kaggle)
   1) Membuka platform Kaggle (kaggle.com).
   2) Melakukan pencarian dataset pada search bar menggunakan kata kunci "Handphone".



Gambar 1.1 halaman pencarian Kaggle dengan kata kunci "phone"

3) Memilih dataset target (price_range), maka cari dataset train.csv yang ada kolom price_rangenya. Untuk dijadikan data latih
4) Mengunduh dataset dalam format terstruktur (.csv) melalui tombol Download.
5) Memeriksa struktur berkas terunduh (train.csv dan test.csv) untuk dipersiapkan ke tahap Data Preprocessing.



Gambar 1.2 halaman review dataset kaggle

C. KESIMPULAN

1) Pemrograman Machine Learning memungkinkan komputer menemukan pola dan aturan secara otomatis berdasarkan data, mengatasi keterbatasan logika kaku pada pemrograman tradisional.

2) Data Collecting merupakan fondasi awal yang vital dalam workflow ML; kualitas dan kecukupan data berbanding lurus dengan keandalan model yang dihasilkan.
3) Platform penyedia data terbuka seperti Kaggle dan repositori open-source mempermudah praktisi ML dalam memperoleh dataset siap latih untuk penyelesaian berbagai problem bisnis/akademis.

PERTEMUAN 5
LATIHAN DATA LOADING DATA CLEANING DAN TRANSFORMATION

A. LANDASAN TEORI

1. Tahapan machine learning
    1) Data loading, yaitu proses mengambil data dari sumber eksternal (seperti berkas berformat CSV atau Excel) dan memuatnya ke dalam lingkungan kerja pemrograman sebagai dataframe. Pemrosesan tabel numerik dan manipulasi struktur data umumnya menggunakan pustaka Pandas. Kualitas dan struktur awal dataset yang dimuat menjadi penentu utama kelancaran tahapan preprocessing serta pelatihan model.
    2) Pembersihan Data (Data Cleaning), yaitu proses pembersihan data yang dilakukan untuk memastikan dataset bebas dari kesalahan penulisan, ketidakselarasan format, maupun nilai yang tidak valid. Prinsip utama dalam tahapan ini adalah menjaga kualitas data input agar model tidak menghasilkan prediksi yang keliru (garbage in, garbage out).
    3) Identifikasi Informasi dan Statistik Deskriptif, yaitu tahap pemeriksaan tipe data dilakukan melalui ringkasan struktur untuk memastikan fitur numerik dan kategorikal terdeteksi secara tepat. Analisis statistik deskriptif (mencakup nilai rata-rata, median, standar deviasi, nilai minimum, dan nilai maksimum) digunakan untuk memahami persebaran data, tingkat variabilitas, serta mendeteksi potensi anomali awal.
    4) Penanganan Nilai Hilang/ catatan data tidak terisi secara lengkap (Missing Value). Strategi penanganannya terbagi menjadi dua kelompok utama:

        a. Imputasi, yaitu mengisi nilai yang hilang menggunakan nilai statistik. Fitur numerik umumnya diisi menggunakan median atau rata-rata (mean), sedangkan fitur kategorikal diisi menggunakan nilai yang paling sering muncul (modus).

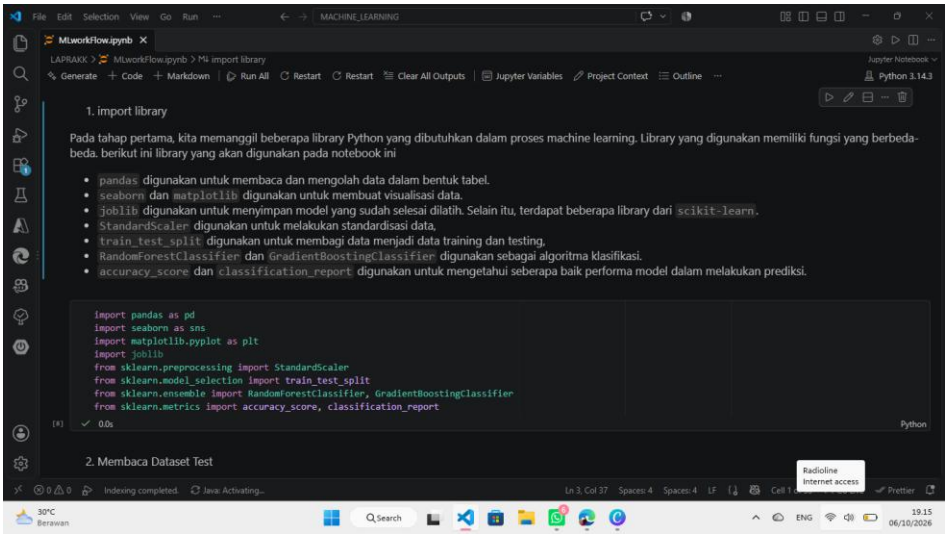
b. Eliminasi, yaitu menghapus kolom atau baris yang memiliki persentase nilai hilang sangat tinggi (misalnya di atas 75%) agar tidak mengganggu proses inferensi model.

5) Penanganan Pencilan (Outliers), outliers merupakan nilai ekstrem yang menyimpang jauh dari kumpulan data lainnya. Deteksi pencilan umumnya dilakukan dengan metode Interquartile Range (IQR), di mana batas bawah ditentukan melalui $\boldsymbol{Q1 - 1.5 \times IQR}$ dan batas atas melalui $\boldsymbol{Q3 + 1.5 \times IQR}$. Data di luar rentang batas tersebut dapat dihilangkan atau diganti dengan nilai batas terdekat untuk mengurangi deviasi varians yang terlalu tinggi.
6) Pemeriksaan Duplikasi Data, pada proses ini data duplikat diidentifikasi dan dihapus dari dataframe guna mencegah bobot model berpihak pada baris data berulang secara tidak proporsional.
7) Skaling dan Transformasi Data, model machine learning berbasis jarak atau optimasi regresi membutuhkan fitur dengan skala yang seragam agar proses konvergensi algoritma berjalan optimal.
8) Standardisasi, yaitu mengubah skala fitur numerik sehingga memiliki nilai rata-rata 0 dan standar deviasi 1 ($\boldsymbol{Z}$-score). Teknik ini cocok digunakan apabila data mendekati distribusi normal dan algoritma yang digunakan sensitif terhadap rentang skala antar variabel.
9) Normalisasi, yaitu mengubah skala nilai fitur ke dalam rentang tertentu, biasanya antara 0 dan 1 (Min-Max Scaling). Teknik ini sangat efektif untuk algoritma berbasis pengukuran jarak seperti K-Nearest Neighbors (KNN).
10) Encoding Data Kategorikal, algoritma machine learning melakukan kalkulasi berbasis operasi matematika numerik sehingga variabel kategorikal harus dikonversi terlebih dahulu ke dalam bentuk angka.

2. One hot encoding dan label encoding

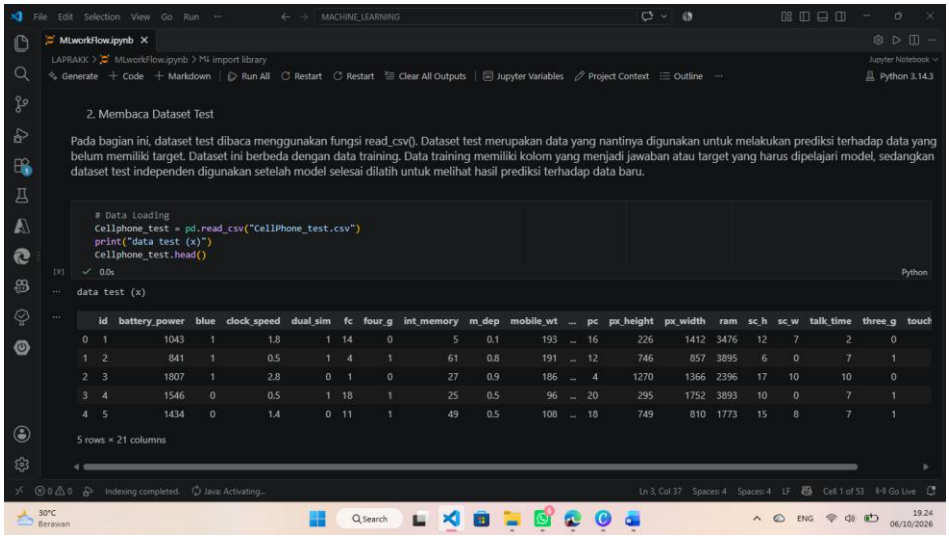
One-Hot Encoding yaitu memecah setiap nilai kategori menjadi kolom biner terpisah (nilai 0 atau 1). Metode ini tepat untuk data nominal tanpa urutan hierarki, namun dapat menambah dimensi kolom secara signifikan. Sedangkan label Encoding yaitu memetakan setiap variabel kategori menjadi nilai bulat numerik berurutan dalam satu kolom yang sama. metode ini lebih hemat memori dan cocok digunakan pada data kategorikal berurutan (ordinal) atau ketika terdapat keterbatasan komputasi.

B. TUGAS PRAKTIKUM



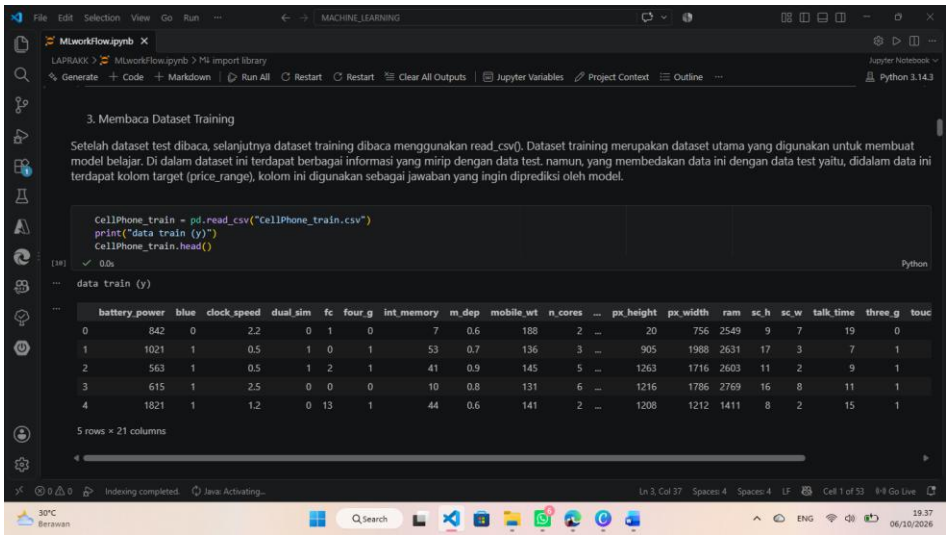
Gambar 2.1 import library python

Note: Penjelasan sudah ada di markdown notebook



Gambar 2.2 latihan data loading (baca data test)

Note: Penjelasan sudah ada di markdown notebook



3. Membaca Dataset Training

Setelah dataset test dibaca, selanjutnya dataset training dibaca menggunakan read_csv(). Dataset training merupakan dataset utama yang digunakan untuk membuat model belajar. Di dalam dataset ini terdapat berbagai informasi yang mirip dengan data test. namun, yang membedakan data ini dengan data test yaitu, didalam data ini terdapat kolom target (price_range), kolom ini digunakan sebagai jawaban yang ingin diprediksi oleh model.

```
CellPhone_train = pd.read_csv("CellPhone_train.csv")
print("data train (y)")
CellPhone_train.head()
```

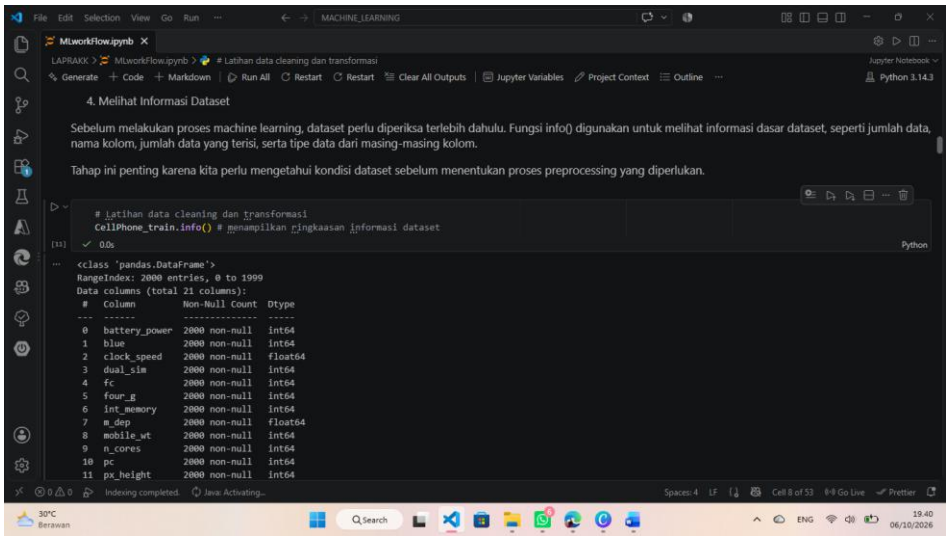
data train (y)

	battery_power	blue	clock_speed	dual_sim	fc	four_g	int_memory	m_dep	mobile_wt	n_cores	...	px_height	px_width	ram	sc_h	sc_w	talk_time	three_g	touc
0	842	0	2.2	0	1	0	7	0.6	188	2	...	20	756	2549	9	7	19	0	
1	1021	1	0.5	1	0	1	53	0.7	136	3	...	905	1988	2631	17	3	7	1	
2	563	1	0.5	1	2	1	41	0.9	145	5	...	1263	1716	2603	11	2	9	1	
3	615	1	2.5	0	0	0	10	0.8	131	6	...	1216	1786	2769	16	8	11	1	
4	1821	1	1.2	0	13	1	44	0.6	141	2	...	1208	1212	1411	8	2	15	1	

5 rows × 21 columns

Gambar 2.2 latihan data loading (baca data test)

Note: Penjelasan sudah ada di markdown notebook



4. Melihat Informasi Dataset

Sebelum melakukan proses machine learning, dataset perlu diperiksa terlebih dahulu. Fungsi info() digunakan untuk melihat informasi dasar dataset, seperti jumlah data, nama kolom, jumlah data yang terisi, serta tipe data dari masing-masing kolom.

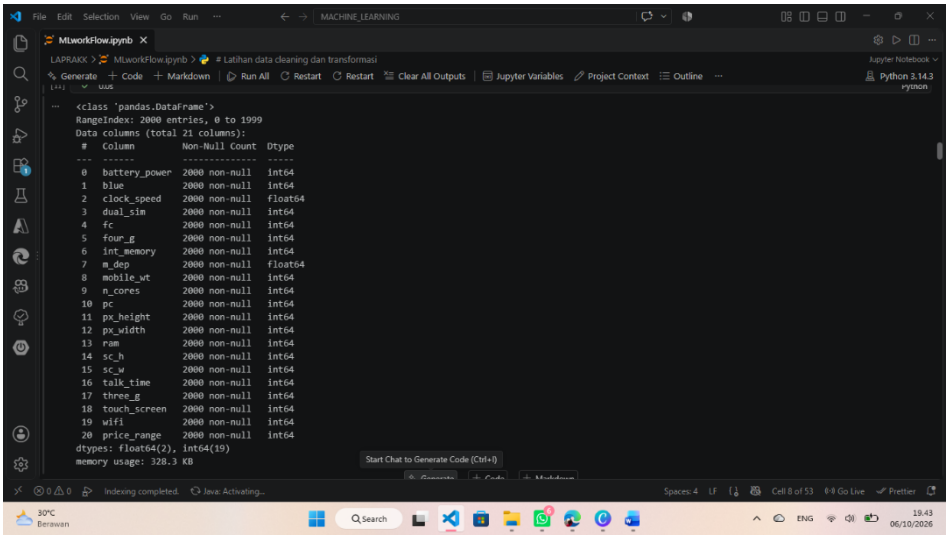
Tahap ini penting karena kita perlu mengetahui kondisi dataset sebelum menentukan proses preprocessing yang diperlukan.

```
# Latihan data cleaning dan transformasi
CellPhone_train.info() # menampilkan ringkasan informasi dataset
```

```
<class 'pandas.DataFrame'>
RangeIndex: 2000 entries, 0 to 1999
Data columns (total 21 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   battery_power  2000 non-null   int64
 1   blue           2000 non-null   int64
 2   clock_speed    2000 non-null   float64
 3   dual_sim       2000 non-null   int64
 4   fc             2000 non-null   int64
 5   four_g         2000 non-null   int64
 6   int_memory     2000 non-null   int64
 7   m_dep          2000 non-null   float64
 8   mobile_wt      2000 non-null   int64
 9   n_cores        2000 non-null   int64
 10  pc             2000 non-null   int64
 11  px_height      2000 non-null   int64
```

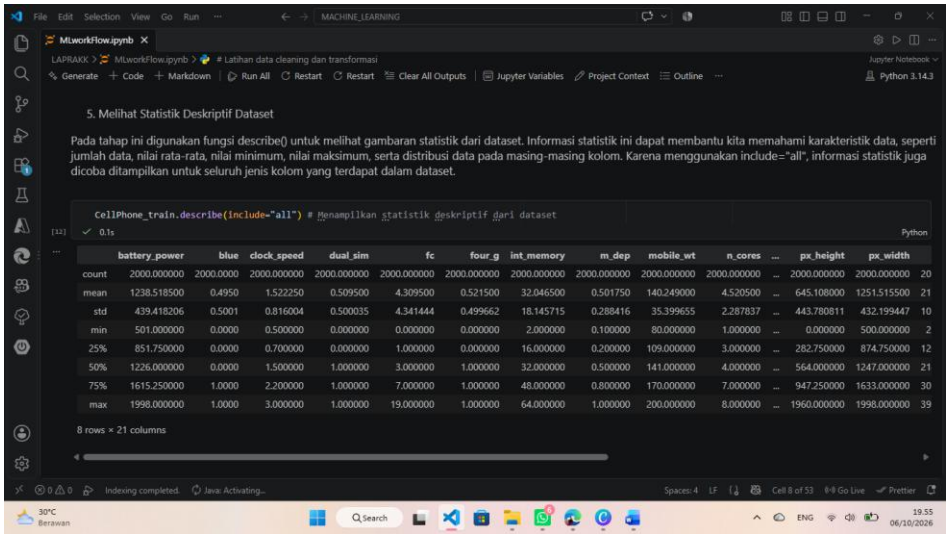
Gambar 2.3 latihan data cleaning (menampilkan informasi dari dataset)

Note: Penjelasan sudah ada di markdown notebook



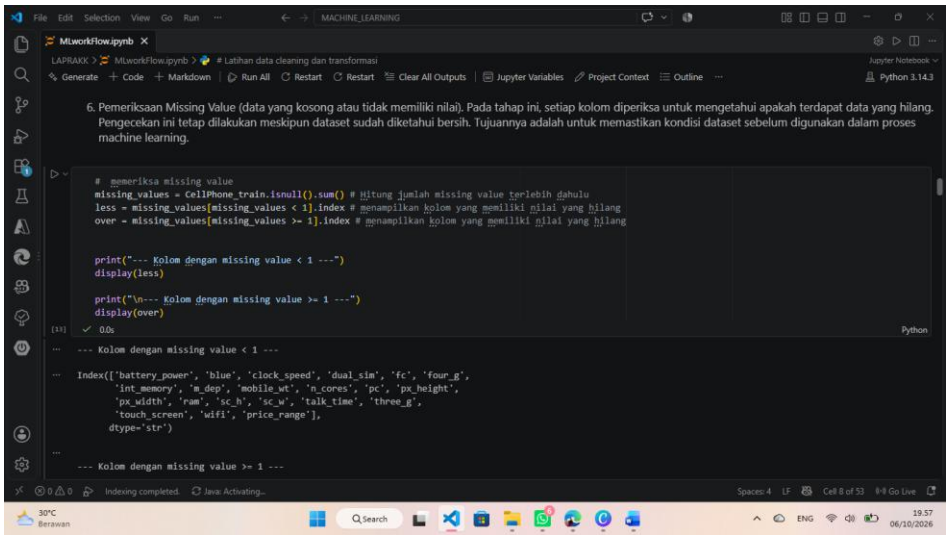
Gambar 2.3 latihan data cleaning dan trasnformation menampilkan informasi dari dataset (output)

Keterangan: dari output diatas dapat disimpulkan bahwa fungsi dari info() adalah menampilkan rincian dari dataset, dari mulai jumlah, kolom dan jenis data didalam kolom tersebut, jumlah jenis tipe data dalam dataset bahkan total memory yang terpakai untuk dataset



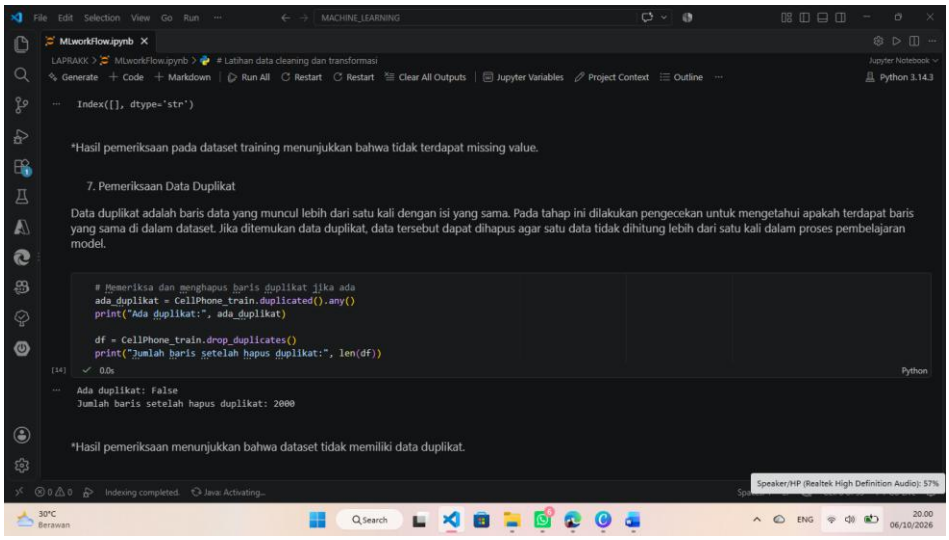
Gambar 2.4 latihan data cleaning dan transformation (menampilkan deskripsi statistik)

Note: Penjelasan sudah ada di markdown notebook



Gambar 2.5 latihan data cleaning dan transformation (pemeriksaan missing values)

Note: Penjelasan sudah ada di markdown notebook



Gambar 2.6 latihan data cleaning dan transformation (pemeriksaan data duplikat)

Note: Penjelasan sudah ada di markdown notebook

C. KESIMPULAN

1. Pentingnya Data Loading dan Inspeksi Awal: Data Loading menggunakan fungsi pd.read_csv() merupakan langkah fundamental untuk memuat dataset ke dalam struktur DataFrame Pandas. Inspeksi struktur awal melalui fungsi .info() dan statistik deskriptif melalui .describe() memberikan gambaran menyeluruh mengenai tipe data, jumlah sampel, serta sebaran nilai awal.

2. Kualitas Dataset Train: Berdasarkan hasil pemeriksaan missing value (.isnull().sum()) dan data duplikat (.duplicated()), dataset CellPhone_train.csv terbukti dalam kondisi sangat baik karena tidak ditemukan nilai yang hilang maupun baris data ganda.
3. Pembersihan Data Kunci Presisi Model: Penanganan missing value, duplikasi, dan pencilan (outliers) sangat krusial untuk mencegah bias model serta memastikan prinsip quality in, quality out pada tahapan machine learning workflow selanjutnya.

PERTEMUAN 5
LATIHAN DATA PROCESSING DAN DATA SPLITTING

A. LANDASAN TEORI

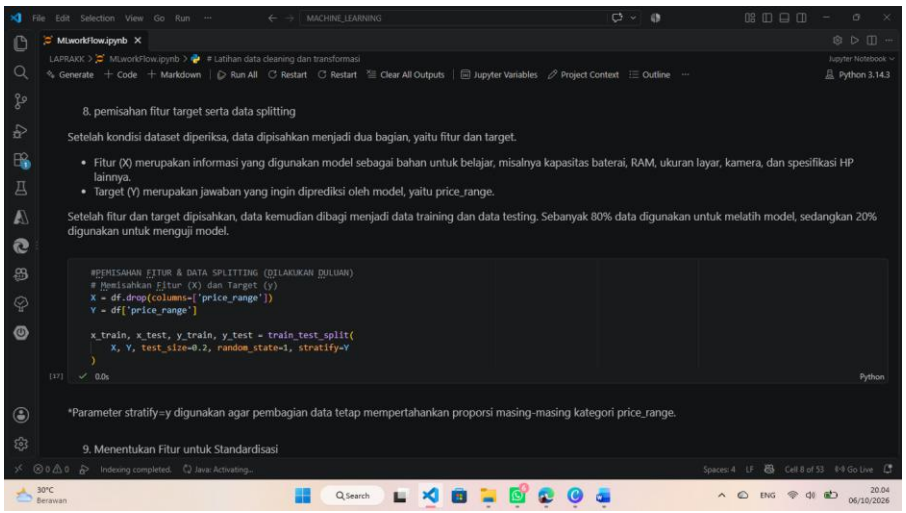
1. Data Splitting

Pembagian Data (Data Splitting) adalah pemisahan dataset menjadi beberapa bagian terpisah, yaitu Training Set, Validation Set, dan Test Set.

- Training Set berarti Bagian dataset terbesar (umumnya 70%–80%) yang digunakan langsung oleh algoritma untuk mempelajari pola data.
- Test Set yaitu Bagian dataset yang disisihkan (umumnya 20%–30%) untuk menguji kinerja generalisasi model terhadap data baru yang belum pernah dilihat sebelumnya.

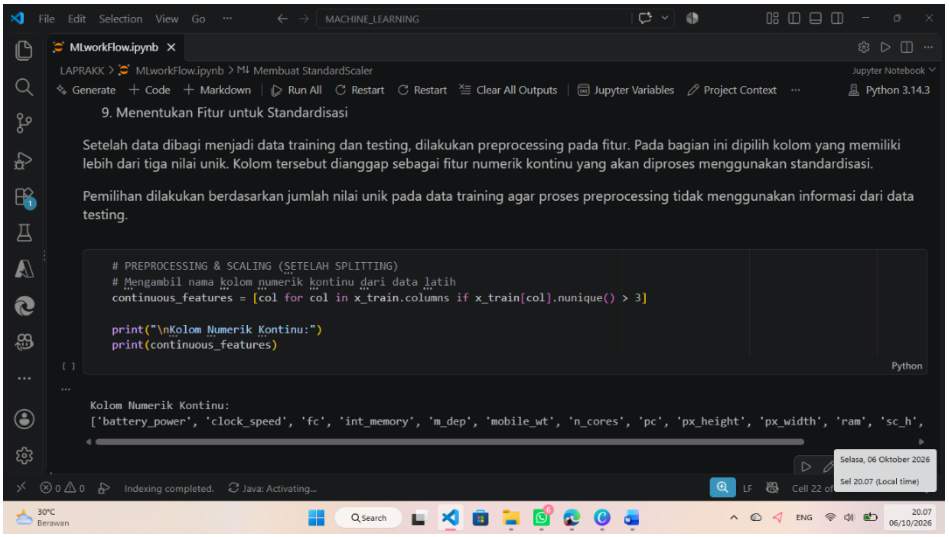
Tujuan dari data splitting ini yatu untuk mencegah terjadinya overfitting (kondisi di mana model menghafal data latih namun gagal memprediksi data baru secara akurat). Kemudian untuk teknik pembagian pada dataset pada praktikum kali ini menggunakan metode holdout menggunakan pemisahan acak dengan penetapan random state untuk menjamin konsistensi pengujian. Pada dataset dengan kelas target yang tidak seimbang, teknik stratified splitting diterapkan agar proporsi tiap kelas target pada data latih dan data uji tetap seimbang.

B. TUGAS PRAKTIKUM



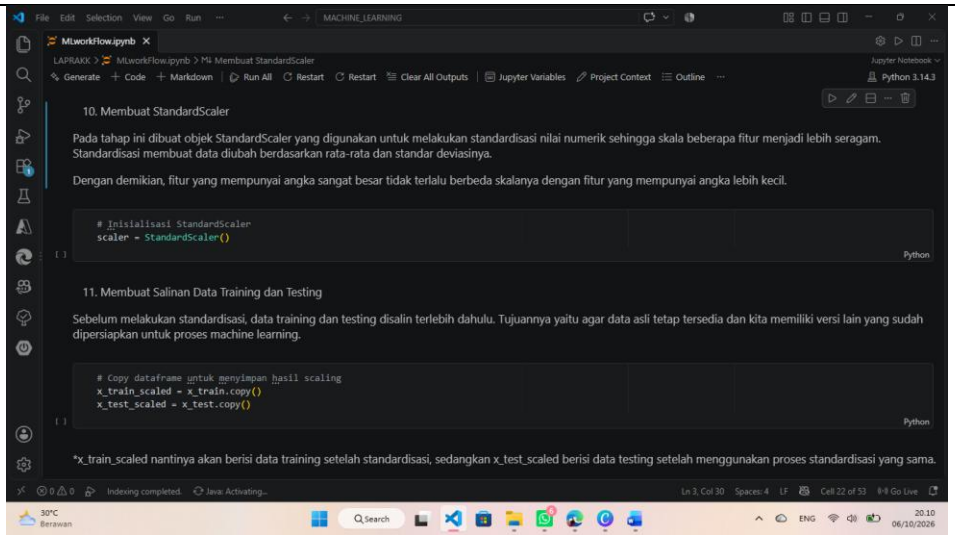
Gambar 3.1 latihan data splitting (memisahkan data fitur dengan data target)

Note: Penjelasan sudah ada di markdown notebook



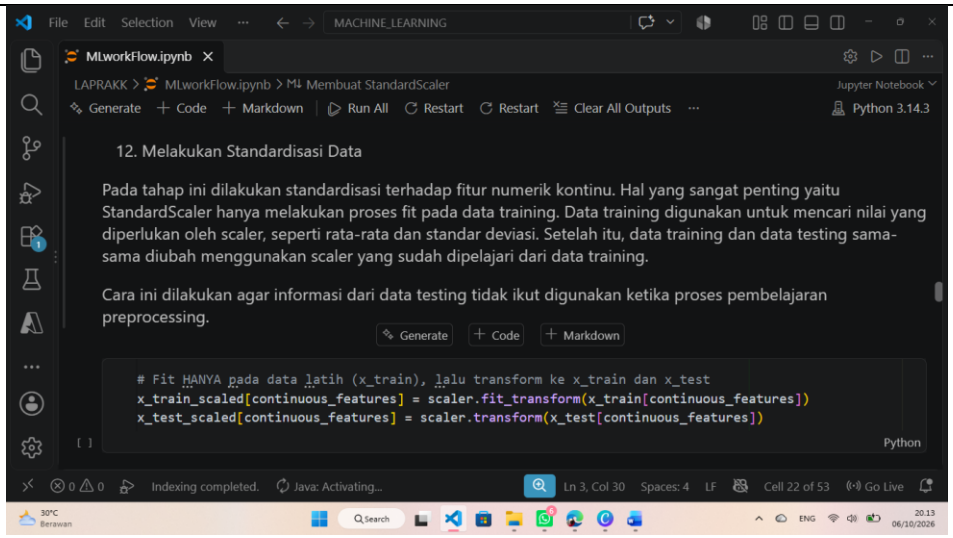
Gambar 3.2 latihan data preprocessing (ambil nama kolom numerik kontinu dari data train)

Note: Penjelasan sudah ada di markdown notebook



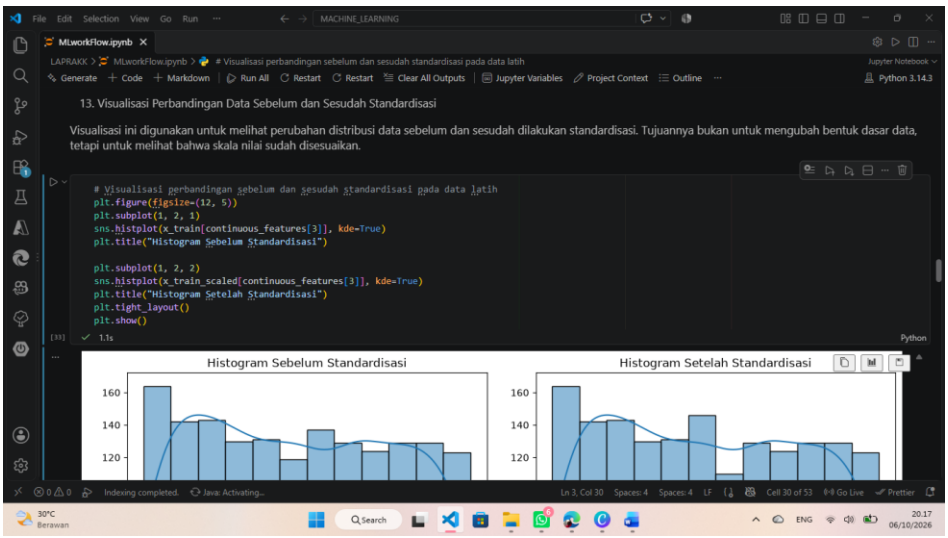
Gambar 3.3 latihan data preprocessing (membuat Salinan standard scaler serta data test dan train)

Note: Penjelasan sudah ada di markdown notebook



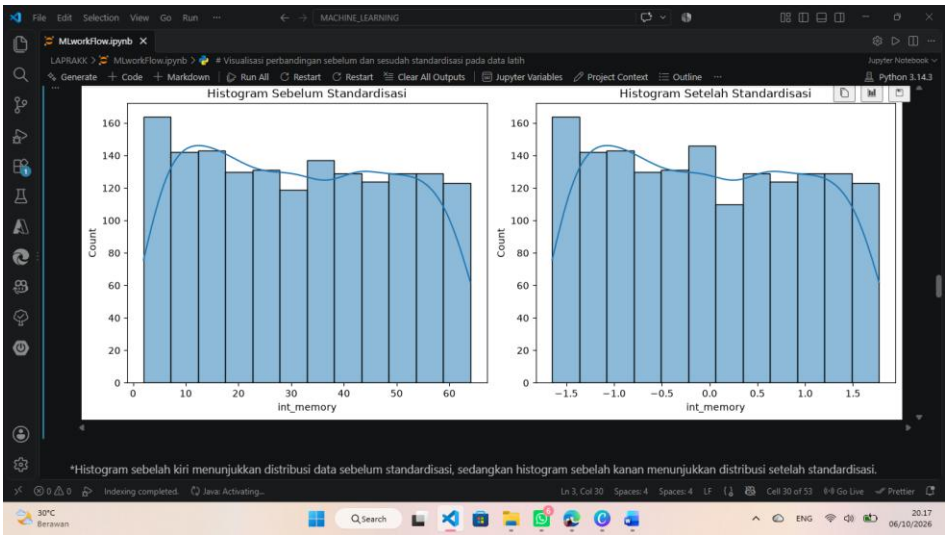
Gambar 3.4 latihan data preprocessing (standarisasi data)

Note: Penjelasan sudah ada di markdown notebook



Gambar 3.5 latihan data preprocessing (perbandingan setelah dan sebelum standarisasi)

Note: Penjelasan sudah ada di markdown notebook



Gambar 3.6 visualisasi data setelah dan sebelum standarisasi

C. KESIMPULAN

1. Pencegahan Data Leakage: Pemisahan data (Data Splitting) menjadi training set (80%) dan testing set (20%) menggunakan train_test_split() harus dilakukan terlebih dahulu sebelum preprocessing (scaling). Hal ini bertujuan untuk mencegah terjadinya kebocoran informasi (data leakage) dari data uji ke data latih.
2. Keseimbangan Proporsi Kelas: Penggunaan parameter stratify=y pada proses splitting berhasil mempertahankan keseimbangan proporsi distribusi kategori target price_range pada data latih dan data uji.
3. Penerapan Standardisasi yang Tepat: Transformasi fitur numerik menggunakan StandardScaler wajib dihitung (fit_transform) hanya pada data latih (x_train), kemudian diterapkan (transform) pada data uji (x_test) agar rentang skala antar variabel numerik kontinu menjadi seragam tanpa mengubah distribusi bentuk dasar data.

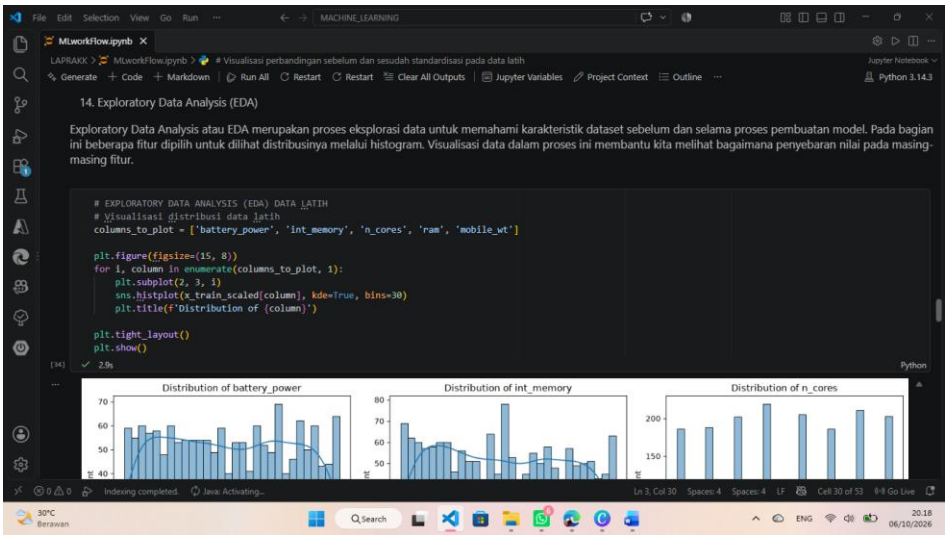
PERTEMUAN 7
LATIHAN EDA DAN ExDA

A. LANDASAN TEORI

1. Eksplorasi dan Eksplanasi Data (EDA & ExDA)

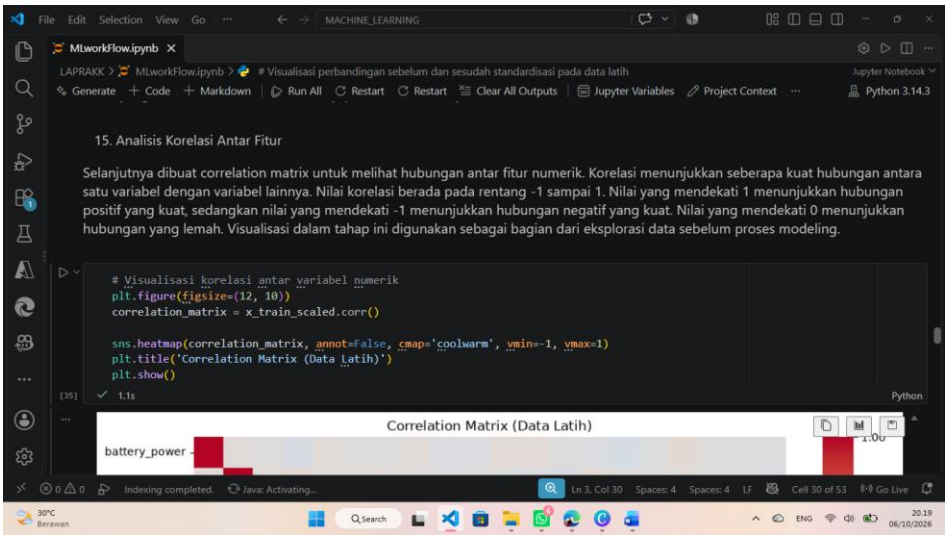
Exploratory Data Analysis (EDA) adalah Pemahaman mendalam terhadap karakteristik data melalui pembuatan histogram, plot distribusi, dan matriks korelasi. Analisis korelasi membantu mengukur kekuatan hubungan linier antar fitur spesifikasi terhadap variabel target. Sedangkan Explanatory Data Analysis (ExDA) adalah Tahap penyampaian wawasan hasil analisis data secara sistematis dan naratif berbasis bukti visual untuk mendukung pengambilan keputusan.

B. TUGAS PRAKTIKUM



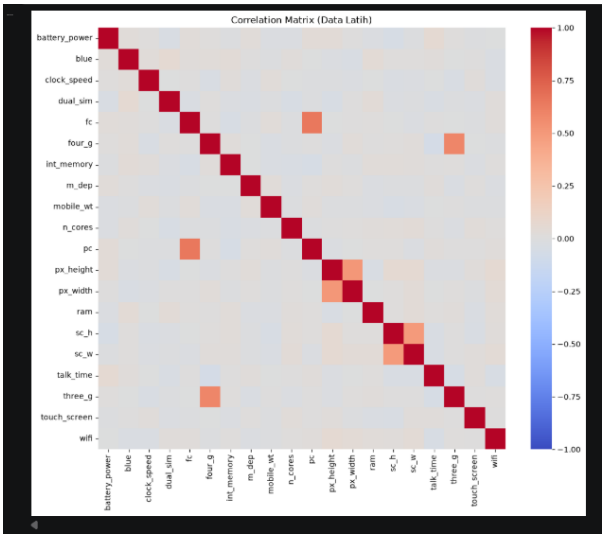
Gambar 4.1 latihan EDA dan ExDA visualisasi distribusi data train

Note: Penjelasan sudah ada di markdown notebook



Gambar 4.2 latihan EDA dan ExDA (analisis korelasi antar fitur)

Note: Penjelasan sudah ada di markdown notebook



Gambar 4.3 visualisai korelasi antar variabel numeri

Keterangan: Visualisasi *Correlation Matrix* menunjukkan korelasi positif yang cukup kuat hanya pada fitur yang spesifikasinya saling berkaitan, seperti resolusi kamera (pc dan fc), dimensi layar (px_height dan px_width, serta sc_h dan sc_w), dan dukungan jaringan (three_g dan four_g). Sebagian besar fitur lainnya berada pada area netral (berwarna abu-abu) yang menandakan tingkat hubungan sangat lemah. Kondisi ini mengindikasikan bahwa dataset bebas dari masalah multikolinearitas tinggi, sehingga seluruh fitur sangat aman dan ideal untuk digunakan dalam pemodelan *machine learning*.

C. KESIMPULAN

1. Pemahaman Karakteristik Fitur (EDA): Exploratory Data Analysis (EDA) menggunakan visualisasi histogram memberikan pemahaman visual mengenai bentuk sebaran dan distribusi frekuensi nilai pada fitur-fitur spesifikasi HP (seperti battery_power, ram, int_memory, dll.).
2. Identifikasi Korelasi Antar Variabel: Pembuatan Correlation Matrix dan peta panas (heatmap) efektif untuk mengukur tingkat kekuatan hubungan linier antar fitur numerik.
3. Dasar Analisis Pemodelan: Analisis korelasi mempermudah identifikasi variabel yang memiliki pengaruh dominan terhadap variabel target maupun deteksi multikolinearitas antar variabel bebas sebagai wawasan pendukung sebelum tahap pemodelan (Explanatory Data Analysis).

PERTEMUAN 8
LATIHAN DATA MODELING

A. LANDASAN TEORI

1. Pembangunan model

   Pembangunan model (*data modeling*) merupakan tahapan dalam *machine learning workflow* setelah pemisahan data (*data splitting*) yang bertujuan untuk memilih, melatih, dan mengevaluasi algoritma agar mampu memprediksi atau mengklasifikasikan variabel target berdasarkan fitur-fitur input. Dalam tahapan ini, penting bagi kita untuk melakukan Pemilihan Algoritma Machine Learning. Dimana Pemilihan algoritma harus disesuaikan dengan tujuan permasalahan, mempertimbangkan jenis data (numerik, kategorikal, campuran), ukuran dataset, serta tingkat linearitas hubungan antara fitur dan target.

   - Gunakan Regresi ketika variabel target bersifat kontinu (misalnya prediksi harga rumah) menggunakan algoritma seperti *Linear Regression*, *LARS*, atau *Gradient Boosting Regressor*.
   - Gunakan Klasifikasi jika variabel target berbentuk kategorikal (misalnya deteksi spam) menggunakan *Logistic Regression*, *Decision Trees*, *Random Forest*, atau *SVM*.
   - Gunakan Clustering untuk mengelompokkan data tanpa label (*unsupervised*) menggunakan *K-Means* atau *DBSCAN*.

2. Pelatihan Model (Model Training)

   Pelatihan model merupakan proses pembelajaran algoritma dari data latih (training set) dengan menyesuaikan parameter atau bobot internalnya. Tujuan dari proses ini adalah meminimalkan kesalahan (error) saat memetakan fitur (input) ke target (output). Pada tahap pemanasan awal tanpa hyperparameter tuning, model dilatih menggunakan konfigurasi bawaan (default).

3. Evaluasi Performa Model

   Evaluasi dilakukan menggunakan *validation/testing set* (x_test) sebagai *unseen data* untuk mengukur kemampuan generalisasi model berdasarkan hasil prediksi

dari fungsi .predict(). Pada permasalahan regresi, evaluasi diukur menggunakan tiga metrik utama:

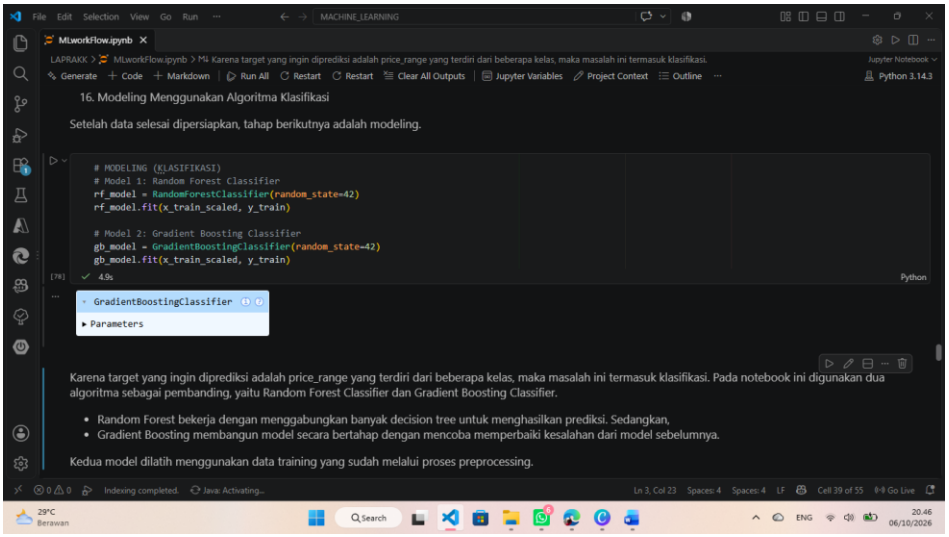
- Mean Absolute Error (MAE): Mengukur rata-rata dari selisih absolut antara nilai prediksi dan nilai aktual secara langsung tanpa memperhitungkan arah kesalahan.
- Mean Squared Error (MSE): Mengukur rata-rata dari kuadrat kesalahan prediksi. Efek kuadrat memberikan penalti lebih besar pada kesalahan skala besar, sehingga lebih sensitif terhadap *outlier*.
- R^2 Score (Koefisien Determinasi): Metrik statistik yang mengukur proporsi varians dari target yang berhasil dijelaskan oleh fitur-fitur di dalam model.

4. Persistensi dan Penyimpanan Model (Model Persistence)

   Model yang telah dilatih dan dievaluasi perlu disimpan ke dalam file fisik agar dapat digunakan pada lingkungan produksi tanpa harus melakukan pelatihan ulang (*retraining*):

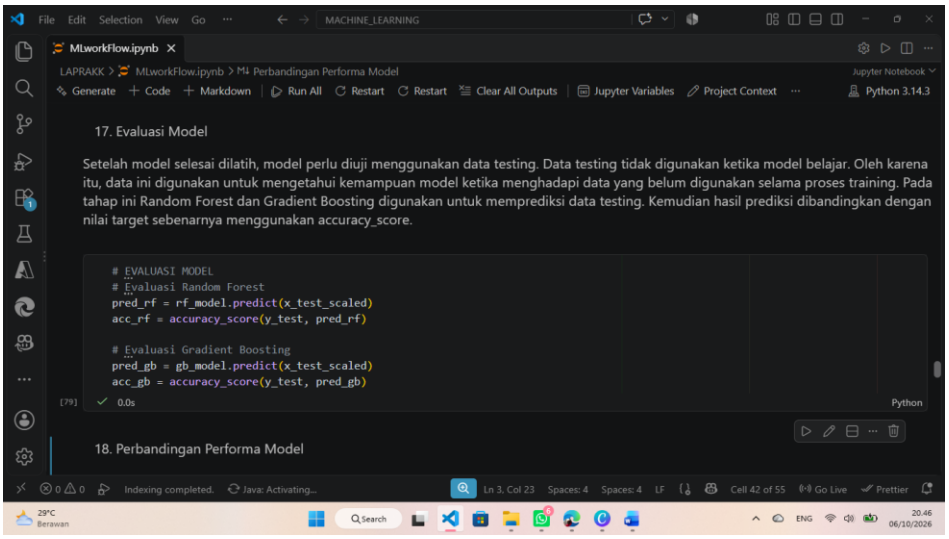
   - Joblib: Pilihan utama yang direkomendasikan untuk model *scikit-learn* karena lebih cepat dan efisien dalam menangani objek berukuran besar.
   - Pickle: Modul standar Python untuk serialisasi berbagai jenis objek Python, namun kurang efisien dibandingkan *joblib* saat menyimpan model Machine Learning berkapasitas besar.

B. TUGAS PRAKTIKUM



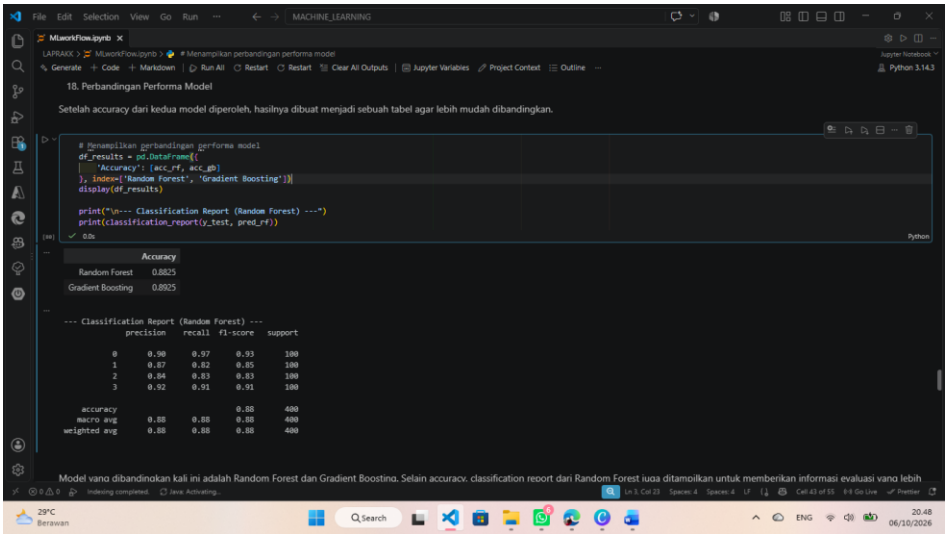
Gambar 5.1 latihan data modeling (algoritma klasifikasi)

Note: Penjelasan sudah ada di markdown notebook



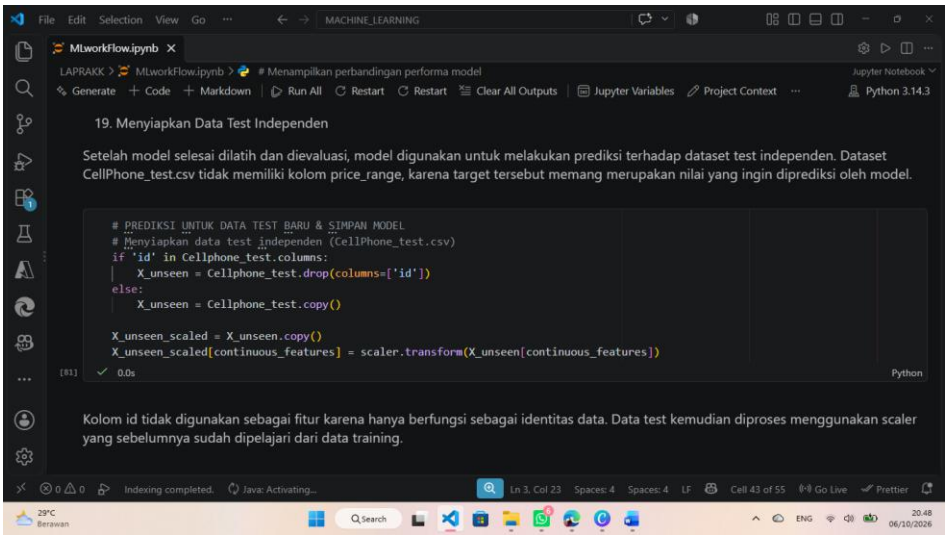
Gambar 5.2 latihan data modeling (evaluasi model)

Note: Penjelasan sudah ada di markdown notebook



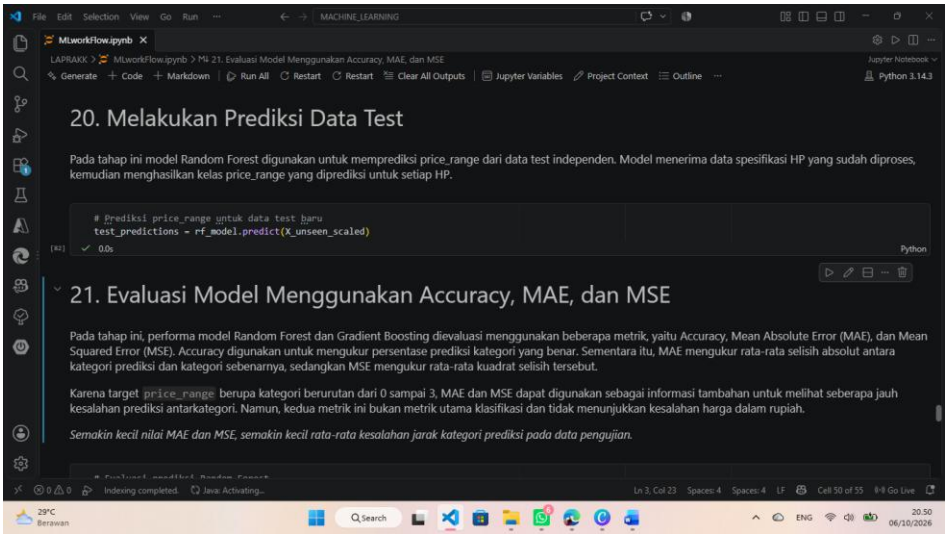
Gambar 5.2 latihan data modeling (perbandingan performa model)

Note: Penjelasan sudah ada di markdown notebook



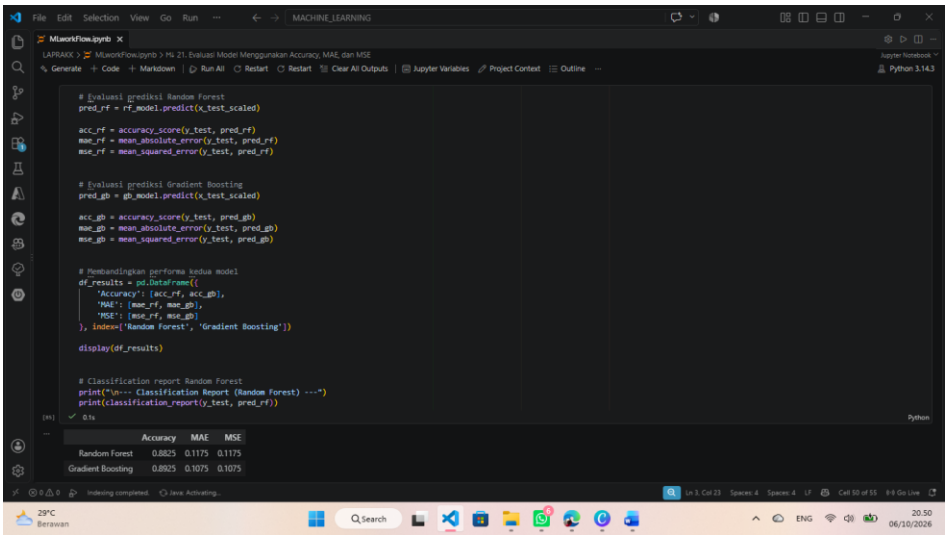
Gambar 5.3 latihan data modeling (menyiapkan data test)

Note: Penjelasan sudah ada di markdown notebook



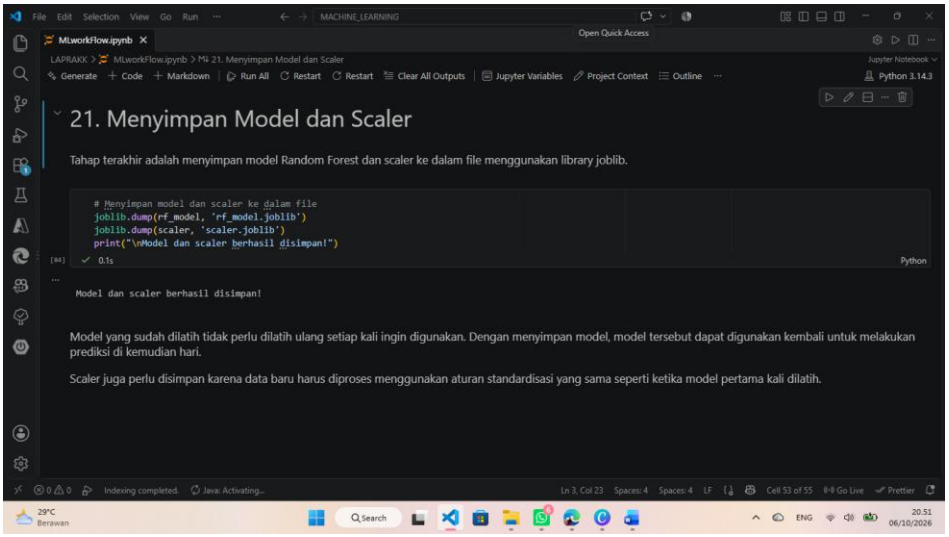
Gambar 5.4 latihan data modeling (prediksi data test)

Note: Penjelasan sudah ada di markdown notebook



Gambar 5.5 penggunaan Accuracy MAE dan MSE untuk mengevaluasi model

Note: Penjelasan sudah ada di markdown notebook



Gambar 5.6 simpan model dan scaler

Note: Penjelasan sudah ada di markdown notebook

C. KESIMPULAN

1. Kesesuaian Jenis Pemodelan: Kasus prediksi price_range (rentang harga ponsel) merupakan permasalahan Klasifikasi Multikelas (multiclass classification), sehingga penggunaan algoritma klasifikasi seperti Random Forest Classifier dan Gradient Boosting Classifier terbukti tepat.
2. Performa Evaluasi Model: Kedua algoritma klasifikasi menunjukkan performa yang sangat baik dengan tingkat akurasi mencapai rentang 88% – 89%. Selain

akurasi, metrik MAE dan MSE memberikan gambaran tambahan bahwa rata-rata kesalahan jarak prediksi antar kategori target tergolong sangat kecil (~0.10–0.11).

3. Persistensi dan Reusabilitas Model: Penyimpanan model (Random Forest) beserta objek scaler ke dalam format .joblib memungkinkan model yang telah dilatih untuk digunakan kembali secara langsung pada data pengujian baru (unseen test data) tanpa perlu melakukan proses pelatihan ulang (retraining).